

INTRODUÇÃO À ROBÓTICA MÓVEL

Aula 25

Edson Prestes
Departamento de Informática Teórica
<http://www.inf.ufrgs.br/~prestes>
prestes@inf.ufrgs.br



Odometria and Métodos de Dead-Reckoning

- Odometria permite boa precisão em curtas distâncias e possui baixo custo.
- Porém, devido à integração incremental do movimento do robô, ela leva ao acúmulo de erros proporcional à distância navegada.
- Ela é amplamente usada por sistemas de navegação em : Algoritmos de localização, mapeamento, exploração, etc.;

Odometria and Métodos de Dead-Reckoning

- Erros sistemáticos e não sistemáticos
 - Odometria é baseada na idéia de que as revoluções da rodas do robô podem ser convertidas em deslocamento linear relativo ao chão.
 - Esta idéia é limitada, pois considere o caso onde o robô está navegando por um chão sujo de óleo.
 - Além disso, existem outras fontes de erros que podem gerar imprecisões na conversão das revolução em deslocamento linear: erros sistemáticos e não sistemáticos.

Odometria and Métodos de Dead-Reckoning

- Fontes de Erros Sistemáticos
 - Diâmetro desigual das rodas;
 - Medida do diâmetro modelado difere da medida do diâmetro real;
 - Desalinhamento das rodas;
 - Resolução finita do encoder;
 - Taxa de amostragem das leituras do encoder finita, etc.

Odometria and Métodos de Dead-Reckoning

- Fontes de Erros Não-Sistemáticos
 - Navegação em pisos irregulares;
 - Derrapagem das rodas devido à:
 - Presença de óleo no chão;
 - Acelerações bruscas;
 - Manobras rápidas;
 - Forças externas (interação com objetos), etc.

Odometria and Métodos de Dead-Reckoning

- Erros sistemáticos e não-sistemáticos
 - Na maioria das superfícies de ambientes internos erros sistemáticos contribuem mais para erros de odometria que erros não sistemáticos.
 - Em superfícies irregulares, erros-não sistemáticos são dominantes.
 - Erros não-sistemáticos podem aparecer inesperadamente. Portanto são mais difíceis de serem modelados.

Odometria and Métodos de Dead-Reckoning

- Erros sistemáticos e não-sistemáticos




Figura extraída de [4]

Localização

- É um componente essencial para um robô ser completamente autônomo.
- Se o robô não sabe sua posição no ambiente ele não pode realizar nenhuma tarefa de navegação
- A odometria por si só não é suficiente para ser usada como estimativa da posição do robô, pois, em geral, ela é contaminada por erros sistemáticos e não sistemáticos.
- Os principais algoritmos são baseados em processo de Filtragem Bayesiana.

Localização



Figuras extraídas de [3]

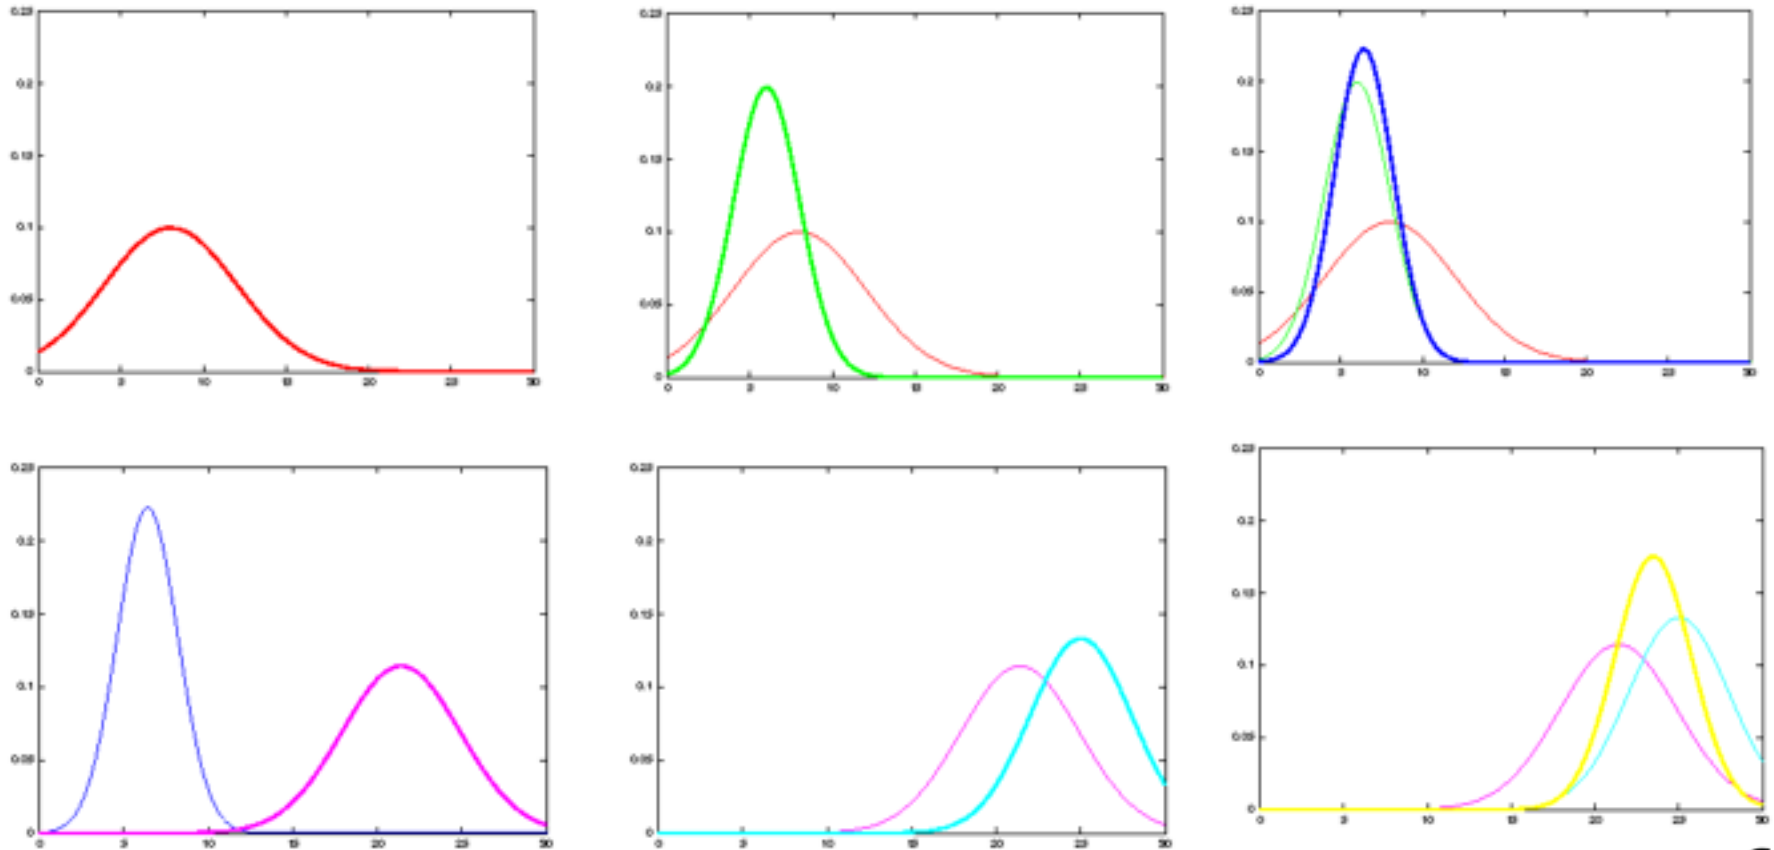
Localização – Estimação Probabilística

- Ao invés de manter **uma simples hipótese** de onde o robô está no mundo, mantém **uma distribuição de probabilidade** sobre o espaço de todas as hipóteses.
- Este tipo de representação leva em consideração às incertezas presentes na movimentação e no sensoramento do robô
- Esta distribuição pode ser multimodal para indicar situações ambíguas ou unimodal quando a certeza sobre a postura do robô é alta.

Localização – Estimação Probabilística

- Considere que o robô conheça sua posição inicial. Logo, a PDF terá um pico estreito (sharp) no local correspondente.
- Quanto mais estreito e alto maior a certeza sobre a estimativa da posição do robô.
- Quando o robô se desloca, o local do pico se desloca e devido a incerteza na movimentação, ele se tornará menor e mais largo. Quanto maior a velocidade do robô e o ruído, mais rápido o pico ficará largo.
- Para evitar isto, é necessário integrar nesta PDF informação sensorial. Isto compensa a perda de informação, fazendo com que o pico se torne mais estreito.

Localização – Estimação Probabilística



Figuras extraídas de [4]

Localização – Filtragem de Kalman

- Filtragem de kalman fornece uma abordagem recursiva para a estimação de estados de um sistema dinâmico na presença de ruídos.
- Ele é caracterizado por manter uma estimativa do estado corrente do sistema x e uma matriz de covariância P do erro de estimativa.
- Podemos visualizar o Filtro de Kalman como sendo aquele que fornece **como saída uma função de densidade probabilística Gaussiana com média x e covariancia P**

Localização – Filtragem de Kalman Linear

Considere o vetor $x(k) \in \mathbb{R}^n$ como o estado do robô no instante $k \in \mathbb{N}$. A evolução do estado do robô e das medidas sensoriais é dada por

$$\begin{aligned}x(k+1) &= F(k)x(k) + G(k)u(k) + v(k) \\ y(k) &= H(k)x(k) + w(k)\end{aligned}$$

Onde

- $u(k) \in \mathbb{R}^m$ é a entrada para o sistema (velocidades, torque, etc);
- $y(k) \in \mathbb{R}^p$ é a saída do sistema e contém os valores dados pelos sensores do robô
- $F(k) \in \mathbb{R}^{n \times n}$ codifica a dinâmica do sistema
- $G(k) \in \mathbb{R}^{n \times m}$ descreve como as entradas afetam a dinâmica.
- $v(k) \in \mathbb{R}^n$ é o ruído gaussiano com média 0 e matriz de covariância $V(k)$.
- $H(k) \in \mathbb{R}^{p \times n}$ descreve como o vetor de estado é mapeado para a saída
- $w(k) \in \mathbb{R}^p$ é o ruído gaussiano com média 0 e matriz de covariância $W(k)$.

Localização – Filtragem de Kalman Linear

Para determinar a melhor estimativa existem dois problemas :

- presença de ruídos desconhecidos $v(k)$ e $w(k)$, que devem ser eliminados pelo Filtro.
- em geral o estado $x(k)$ não é observável diretamente a partir das saídas pois $H(k)$ pode não ser invertível

O estado estimado deve ser reconstruído usando o histórico temporal dos sinais $y(k)$ e $u(k)$ com os parâmetros $F(k)$, $G(k)$, $H(k)$, $V(k)$ e $W(k)$. Esta reconstrução é feita por um dispositivo chamado observador.

O filtro de Kalman é tanto observador quanto filtro.

Localização – Filtragem de Kalman Linear Simples Observador

Considere um sistema discreto sem ruído

$$x(k+1) = F(k)x(k) + G(k)u(k)$$

$$y(k) = H(k)x(k)$$

H é assumido ser uma matriz full rank a cada instante k. Logo, o determinante de H não é 0.

O observador executará um processo de dois passos.

- Dada uma estimativa do estado corrente

$$\hat{x}(k | k)$$

Irá gerar uma predição de acordo com a dinâmica do sistema

$$\hat{x}(k+1|k) = F(k)\hat{x}(k|k) + G(k)u(k)$$

Localização – Filtragem de Kalman

Linear – Simples Observador

O segundo passo é corrigir a predição baseada na saída $y(k+1)$ para gerar a próxima estimativa

$$\hat{x}(k+1 | k+1)$$

É importante considerar que dada a saída $y(k+1)$ o estado do sistema é restrito ao seguinte hiperplano

$$\Omega = \{x \in R^n | H(k+1)x = y(k+1)\}$$

Portanto, a melhor estimativa $\hat{x}(k+1 | k+1)$ será o ponto no hiperplano mais próximo de $\hat{x}(k+1 | k)$

Localização – Filtragem de Kalman Linear – Simples Observador




Figura extraída de [1]

$$\Delta x = \hat{x}(k+1 | k+1) - \hat{x}(k+1 | k)$$

Δx é perpendicular à Ω

$$\Delta x \in \text{column}(H(k+1)^T)$$

$\text{column}(H(k+1))$ é o espaço de colunas de $H(k+1)$, ou seja, o espaço que corresponde a todas as combinações lineares das colunas de H .

Logo,

$$\Delta x = H(k+1)^T \gamma$$

para $\gamma \in \mathbb{R}^p$

Localização – Filtragem de Kalman

Linear – Simples Observador

Considere a inovação

$$v = y(k + 1) - H(k + 1)\hat{x}(k + 1|k)$$

Como sendo a diferença entre o que os sensores reportam e o que reportariam se a predição estivesse certa.

Sabemos que $\Delta x = H(k + 1)^T \gamma$

Logo γ , pode ser escrito como uma função linear de v , i.e., $\gamma = Kv$, para $K \in \mathbb{R}^{p \times p}$. Portanto temos,

$$\Delta x = H(k + 1)^T K v$$

Lembrando que

$$\hat{x}(k + 1|k + 1) = \hat{x}(k + 1|k) + \Delta x$$

Localização – Filtragem de Kalman Linear – Simples Observador

$$\Delta x = H(k+1)^T K v$$

K deve ser escolhido de forma que

$$H(k+1)(\hat{x}(k+1|k) + \Delta x) = y(k+1)$$

$$H(k+1)\Delta x = y(k+1) - H(k+1)\hat{x}(k+1|k) = v$$

Substituindo Δx ,

$$H(k+1)H(k+1)^T K v = v$$

encontramos

$$K = (H(k+1)H(k+1)^T)^{-1}$$

Localização – Filtragem de Kalman Linear – Simples Observador

Sistema:
$$x(k+1) = Fx(k) + Gu(k)$$
$$y(k) = Hx(k)$$

Predição:
$$\hat{x}(k+1 | k) = F\hat{x}(k | k) + Gu(k)$$

Correção :
$$\Delta x = H(k+1)^T K v$$

onde
$$K = (H(k+1)H(k+1)^T)^{-1}$$
$$v = y(k+1) - H(k+1)\hat{x}(k+1 | k)$$

Atualização:
$$\hat{x}(k+1 | k+1) = \hat{x}(k+1 | k) + \Delta x$$

Localização – Filtragem de Kalman Linear – Simples Observador

- Na atualização, o ajuste no estado do robô é sempre perpendicular ao hiperplano
- Erros na direção paralela à Ω nunca serão corrigidos.
- Como resultado, o estado estimado não convergirá para o estado real do sistema na maioria dos casos[1].
- A vantagem deste estimador é que as idéias usadas são as mesma do filtro de Kalman.

Localização – Filtragem de Kalman

Observando com uma PDF

- O observador anterior produz uma estimativa que é um vetor.
- A estimativa produzida por um Filtro de Kalman é uma distribuição gaussiana multivariada.
- Ou seja, o filtro de kalman além de fornecer um vetor de estado estimado $\hat{x}(k|k)$ fornece também uma matriz de covariância do erro da estimativa $P(k|k)$.

Localização – Filtragem de Kalman

Observando com uma PDF

Considere o seguinte sistema com ruído na dinâmica, mas sem ruído nas medidas

$$x(k+1) = F(k)x(k) + G(k)u(k) + v(k)$$

$$y(k) = H(k)x(k)$$

Ruído

Onde $v(k) \in R^n$ é um ruído gaussiano de média zero e matriz de covariância $V(k)$.

Usando $\hat{x}(k|k)$, temos

$$\hat{x}(k+1|k) = F(k)\hat{x}(k|k) + G(k)u(k)$$

pois o valor esperado de $v(k)$ é zero

Localização – Filtragem de Kalman

Observando com uma PDF

A matriz de covariância é dada por

$$P(k+1|k) = E\left((x(k+1) - \hat{x}(k+1|k))(x(k+1) - \hat{x}(k+1|k))^T\right)$$

Substituindo o valor de $x(k+1)$ e $\hat{x}(k+1|k)$ encontramos

$$P(k+1|k) = E\left[(F(k)x(k) + G(k)u(k) + v(k) - (F(k)\hat{x}(k|k) + G(k)u(k)))\right. \\ \left.(F(k)x(k) + G(k)u(k) + v(k) - (F(k)\hat{x}(k|k) + G(k)u(k)))^T\right]$$

Após algumas manipulações temos

$$P(k+1|k) = E\left[F(k)(x(k) - \hat{x}(k|k))(x(k) - \hat{x}(k|k))^T F(k)^T\right. \\ \left.+ 2F(k)(x(k) - \hat{x}(k|k))v(k)^T + v(k)v(k)^T\right]$$

Localização – Filtragem de Kalman

Observando com uma PDF

Usando a propriedade da soma do valor esperado, temos

$$P(k+1|k) = E[F(k)(x(k) - \hat{x}(k|k))(x(k) - \hat{x}(k|k))^T F(k)^T] \\ + E[2F(k)(x(k) - \hat{x}(k|k))v(k)^T] + E[v(k)v(k)^T]$$

Como $v(k)$ é independente de $x(k)$ e de $\hat{x}(k|k)$

$$E[(x(k) - \hat{x}(k|k))v(k)] = E[(x(k) - \hat{x}(k|k))]E[v(k)]$$

Como $E[v(k)] = 0$,

$$P(k+1|k) = F(k) \boxed{E[(x(k) - \hat{x}(k|k))(x(k) - \hat{x}(k|k))^T]} F(k)^T \\ + E[v(k)v(k)^T]$$

Torna-se

$$P(k+1|k) = F(k) \boxed{P(k|k)} F(k)^T + V(k)$$

Localização – Filtragem de Kalman – Observando com uma PDF

Para encontrar a equação de atualização, escolhemos $\hat{x}(k+1|k+1)$ que seja o mais provável ponto no hiperplano

$$\Omega = \{x \in R^n | H(k+1)x = y(k+1)\}$$

ou seja, o que maximiza a distribuição gaussiana definida por $\hat{x}(k+1|k)$ e $P(k+1|k)$, i.e.,

$$P(x) = \frac{1}{\sqrt{(2\pi)^n |P(k+1|k)|}} e^{-\frac{1}{2}(x - \hat{x}(k+1|k))^T P(k+1|k)^{-1} (x - \hat{x}(k+1|k))}$$

A maximização de $P(x)$, envolve a minimização do expoente de e , i.e.,

$$(x - \hat{x}(k+1|k))^T P(k+1|k)^{-1} (x - \hat{x}(k+1|k))$$

Localização – Filtragem de Kalman – Observando com uma PDF

A distância e o produto interno de Mahalanobis[1] entre duas variáveis aleatórias x e y e matriz de covariância S são dados por

$$||x - y||_M^2 = (x - y)^T S^{-1} (x - y)$$

Logo, a minimização de $(x - \hat{x}(k+1|k))^T P(k+1|k)^{-1} (x - \hat{x}(k+1|k))$

Consiste em calcular $x \in \Omega$, ou seja, $\hat{x}(k+1|k+1)$ de forma a minimizar

$$||x - \hat{x}(k+1|k)||_M = ||\Delta x||_M = ||\hat{x}(k+1|k+1) - \hat{x}(k+1|k)||_M$$

Localização – Filtragem de Kalman – Observando com uma PDF

Δx é ortogonal a Ω com relação ao produto interno de mahalanobis, ou seja, influenciada por $P(k+1|k)$.

Logo, $\Delta x = P(k+1|k)H(k+1)^T \gamma$


Considerando a inovação como

$$i = y(k+1) - H(k+1)x(k+1|k)$$

Temos $\Delta x = P(k+1|k)H(k+1)^T K i$, para $K \in R^p$. De forma similar ao apresentado no observador simples, temos que ter

$$H(k+1)(\hat{x}(k+1|k) + \Delta x) = y(k+1)$$

$$H(k+1)\Delta x = y(k+1) - H(k+1)\hat{x}(k+1|k) = i$$



Localização – Filtragem de Kalman

Observando com uma PDF

Substituindo Δx ,

$$H(k+1)P(k+1|k)H(k+1)^T Ki = i$$

Encontramos

$$K = (H(k+1)P(k+1|k)H(k+1)^T)^{-1}$$

Localização – Filtragem de Kalman

Observando com uma PDF

Sistema: $x(k+1) = F(k)x(k) + G(k)u(k) + v(k)$
 $y(k) = H(k)x(k)$

Predição: $\hat{x}(k+1|k) = F(k)\hat{x}(k|k) + G(k)u(k)$
 $P(k+1|k) = F(k)P(k|k)F(k)^T + V(k)$

Correção: $\Delta x = P(k+1|k)H(k+1)^T K i$
onde $K = (H(k+1)P(k+1|k)H(k+1)^T)^{-1}$
 $i = y(k+1) - H(k+1)\hat{x}(k+1|k)$

Atualização: $\hat{x}(k+1|k+1) = \hat{x}(k+1|k) + \Delta x$
 $P(k+1|k+1) = P(k+1|k) - P(k+1|k)H(k+1)^T K H P(k+1|k)$

Localização – Filtragem de Kalman Observando com uma PDF

- Como o observador simples, este novo observador possui alguns problemas[1]:
 - Devido ao fato de não termos considerado ruído na leitura dos sensores, as equações de atualização farão com que a matriz de covariância se torne singular.
 - Uma matriz singular possui determinante igual a 0, o que é coerente com o fato de que as medidas sensoriais não possuem incertezas.
 - Isto prejudica a distribuição gaussiana que usa a inversa da matriz de covariância.

Localização – Filtragem de Kalman

- O filtro de Kalman usa os conceitos e mecanismos apresentados anteriormente, com a diferença de que o sistema é descrito por

$$x(k+1) = F(k)x(k) + G(k) u(k) + v(k)$$

$$y(k) = H(k)x(k) + w(k)$$

Onde

- $u(k) \in \mathbb{R}^m$ é a entrada para o sistema (velocidades, torque, etc);
- $y(k) \in \mathbb{R}^p$ é a saída do sistema e contém os valores dados pelos sensores do robô
- $F(k) \in \mathbb{R}^{n \times n}$ codifica a dinâmica do sistema
- $G(k) \in \mathbb{R}^{n \times m}$ descreve como as entradas influenciam a dinâmica.
- $v(k) \in \mathbb{R}^n$ é o ruído gaussiano com média 0 e matriz de covariância $V(k)$.
- $H(k) \in \mathbb{R}^{p \times n}$ descreve como o vetor de estado é mapeado para a saída
- $w(k) \in \mathbb{R}^p$ é o ruído gaussiano com média 0 e matriz de covariância $W(k)$.

Localização – Filtragem de Kalman

Observando com uma PDF

Sistema: $x(k+1) = F(k)x(k) + G(k)u(k) + v(k)$

$$y(k) = H(k)x(k) + w(k)$$

Predição: $\hat{x}(k+1|k) = F(k)\hat{x}(k|k) + G(k)u(k)$

$$P(k+1|k) = F(k)P(k|k)F(k)^T + V(k)$$

Correção: $\Delta x = P(k+1|k)H(k+1)^T K i$

onde

$$K = (H(k+1)P(k+1|k)H(k+1)^T + W(k+1))^{-1}$$

$$i = y(k+1) - H(k+1)\hat{x}(k+1|k)$$

Novo termo

Atualização: $\hat{x}(k+1|k+1) = \hat{x}(k+1|k) + \Delta x$

$$P(k+1|k+1) = P(k+1|k) - P(k+1|k)H(k+1)^T K H P(k+1|k)$$

Localização – Filtragem de Kalman –

Exemplo – Dead Reckoning

Considere um robô que se move em linha reta com estado $x = [x_r \ v_r]^T$ e u como sendo a força que se aplica ao robô. Sabemos pela segunda lei de newton que

$$\frac{dv_r}{dt} = \frac{u}{m} \quad \text{ou} \quad \frac{v_r(k+1) - v_r(k)}{T} = \frac{u(k)}{m}$$

Logo, o próximo estado do robô é dado por

$$x(k+1) = \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix} x(k) + \begin{bmatrix} 0 \\ \frac{T}{m} \end{bmatrix} u(k) + v(k)$$

$$\triangleq Fx(k) + Gu(k) + v(k)$$

$$y(k+1) = [0 \ 1]x(k+1) + w(k)$$

$$\triangleq Gx(k) + w(k)$$

Ruído gaussiano
com média zero

O robô possui um sensor
que mede velocidade.

Localização – Filtragem de Kalman – Exemplo – Dead Reckoning

$$\begin{aligned}x(k+1) &= \begin{bmatrix} 1 & T \\ 0 & 1 \end{bmatrix} x(k) + \begin{bmatrix} 0 \\ \frac{T}{m} \end{bmatrix} u(k) + v(k) \\ &\triangleq Fx(k) + Gu(k) + v(k),\end{aligned}$$

$$\begin{aligned}y(k+1) &= [0 \quad 1] x(k) + w(k) \\ &\triangleq Gx(k) + w(k),\end{aligned}$$

Em [1], são assumidos os seguintes parâmetros $m=1$, $T=0.5$, $W=0.5$ (variância na medida) e matriz de covariância V

$$V = \begin{bmatrix} 0.2 & 0.05 \\ 0.05 & 0.1 \end{bmatrix}$$

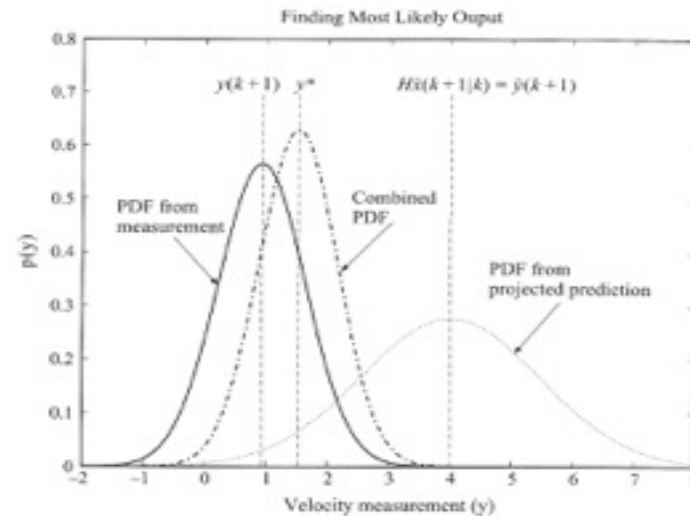

No instante k

$$u(k) = 0$$

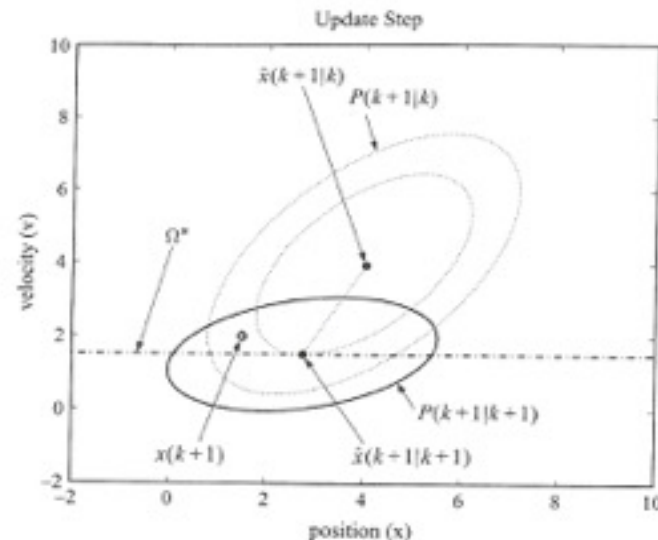
$$\hat{x}(k|k) = [2, 4]^T$$

$$P(k|k) = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$$

Localização – Filtragem de Kalman – Exemplo – Dead Reckoning



Figuras extraídas de [1]



Localização – Filtragem de Kalman – Exemplo – Dead Reckoning

- A incerteza diminuiu na direção vertical devido à informação obtida pelo sensor de velocidade, porém existe perda de informação na direção da posição.
- Este problema não ocorre devido ao Filtro de Kalman, mas devido ao fato do sistema não ser observável, ou seja, o estado do sistema não pode ser recuperado a partir das saídas disponíveis. Logo, o erro esperado irá crescer ilimitadamente.
- Se o sistema é observável, a estimativa fornecida pelo Filtro de Kalman converge, ou seja, o erro esperado entre o estado atual e o estado estimado é limitado.




Figura extraída de [1]

Localização – Filtragem de Kalman – Filtro de Kalman Estendido

Em geral, os sistemas dinâmicos são não-lineares. Portanto, temos que estender o Filtro de Kalman para tratar a não-linearidade do sistema. Considere o seguinte sistema

$$\begin{aligned}x(k+1) &= f(x(k), u(k), k) + v(k) & f: \mathbb{R}^n \times \mathbb{R}^m \times \mathbb{Z}^+ &\rightarrow \mathbb{R}^n \\y(k) &= h(x(k), k) + w(k), & h: \mathbb{R}^n \times \mathbb{Z}^+ &\rightarrow \mathbb{R}^p\end{aligned}$$

A fase de predição é dada pelas equações

$$\begin{aligned}\hat{x}(k+1|k) &= f(\hat{x}(k|k), u(k), k) \\P(k+1|k) &= F(k)P(k|k)F(k)^T + V(k)\end{aligned}$$

onde

$$F(k) = \left. \frac{\partial f}{\partial x} \right|_{x=\hat{x}(k|k)} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \cdots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \cdots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \cdots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}_{x=\hat{x}(k|k)}$$

Localização – Filtragem de Kalman – Filtro de Kalman Estendido

Correção: $\hat{x}(k+1|k+1) = \hat{x}(k+1|k) + R\nu$
 $P(k+1|k+1) = P(k+1|k) - RH(k+1)P(k+1|k)$

onde $\nu = y(k+1) - h(x(k+1|k), k+1)$
 $S = H(k+1)P(k+1|k)H(k+1)^T + W(k+1)$
 $R = P(k+1|k)H(k+1)^T S^{-1}$

e

$$H(k+1) = \left. \frac{\partial h}{\partial x} \right|_{x=\hat{x}(k+1|k)} = \begin{bmatrix} \frac{\partial h_1}{\partial x_1} & \frac{\partial h_1}{\partial x_2} & \dots & \frac{\partial h_1}{\partial x_n} \\ \frac{\partial h_2}{\partial x_1} & \frac{\partial h_2}{\partial x_2} & \dots & \frac{\partial h_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial h_p}{\partial x_1} & \frac{\partial h_p}{\partial x_2} & \dots & \frac{\partial h_p}{\partial x_n} \end{bmatrix}_{x=\hat{x}(k+1|k)}$$

Localização – Filtragem de Kalman – Exemplo – Filtro de Kalman Estendido

Considere um robô capaz de detectar landmarks previamente mapeados no ambiente. O estado do robô no instante k é dado por

$$x(k) = [x_r(k), y_r(k), \theta_r(k)]^T$$

E a entrada de controle é dada por $u(k) = [u_1(k), u_2(k)]^T$ onde $u_1(k)$ e $u_2(k)$ representam as velocidades linear e angular.

O sistema dinâmico é dado por

$$x(k+1) = \begin{bmatrix} \cos \theta_r(k) u_1(k) + x_r(k) \\ \sin \theta_r(k) u_1(k) + y_r(k) \\ u_2(k) + \theta_r(k) \end{bmatrix} + v(k)$$

O ambiente possui n_ℓ landmarks com posição $(x_{\ell i}, y_{\ell i})$ porém o robô consegue apenas ver apenas uma quantidade $p(k)$ a cada instante k . A função abaixo associa cada landmark visto com os conhecidos previamente.

$$a : \{1, 2, \dots, p(k)\} \rightarrow \{1, 2, \dots, n_\ell\}$$

Localização – Filtragem de Kalman – Exemplo – Filtro de Kalman Estendido

A saída do sistema é dada por

$$y(k) = \begin{bmatrix} h_1(x(k), a(1)) \\ h_2(x(k), a(2)) \\ \vdots \\ h_{p(k)}(x(k), a(p(k))) \end{bmatrix} + \begin{bmatrix} w_1(k) \\ w_2(k) \\ \vdots \\ w_{p(k)}(k) \end{bmatrix} \quad \text{com} \quad h_j(x(k), j) = \begin{bmatrix} \sqrt{(x_r(k) - x_{lj})^2 + (y_r(k) - y_{lj})^2} \\ \text{atan2}(y_r(k) - y_{lj}, x_r(k) - x_{lj}) - \theta_r(k) \end{bmatrix}$$

Como a dinâmica do sistema é dada por

$$x(k+1) = \begin{bmatrix} \cos \theta_r(k) u_1(k) + x_r(k) \\ \sin \theta_r(k) u_1(k) + y_r(k) \\ u_2(k) + \theta_r(k) \end{bmatrix} + v(k) \quad \leftarrow f(x(k), u(k), k)$$

A Jacobiana de f é

$$F = \begin{bmatrix} 1 & 0 & -\sin \theta_r(k) u_1(k) \\ 0 & 1 & \cos \theta_r(k) u_1(k) \\ 0 & 0 & 1 \end{bmatrix}$$

Lembrando que

$$F(k) = \left. \frac{\partial f}{\partial x} \right|_{x=\hat{x}(k|k)} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} & \dots & \frac{\partial f_1}{\partial x_n} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} & \dots & \frac{\partial f_2}{\partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial f_n}{\partial x_1} & \frac{\partial f_n}{\partial x_2} & \dots & \frac{\partial f_n}{\partial x_n} \end{bmatrix}_{x=\hat{x}(k|k)}$$

Localização – Filtragem de Kalman – Exemplo – Filtro de Kalman Estendido

A matriz H que é usada para produzir a saída do Filtro é definida por

$$H(k+1) = \begin{bmatrix} H_1(k+1, a(1)) \\ H_2(k+1, a(2)) \\ \vdots \\ H_{p(k+1)}(k+1, a(p(k+1))) \end{bmatrix} = \begin{bmatrix} \left. \frac{\partial h_1}{\partial x} \right|_{x=\hat{x}(k+1|k)} \\ \left. \frac{\partial h_2}{\partial x} \right|_{x=\hat{x}(k+1|k)} \\ \vdots \\ \left. \frac{\partial h_{p(k+1)}}{\partial x} \right|_{x=\hat{x}(k+1|k)} \end{bmatrix}$$

com

$$H_i(k+1, j) = \begin{bmatrix} \frac{(\hat{x}_r(k+1|k) - x_{\ell j})}{\sqrt{(\hat{x}_r(k+1|k) - x_{\ell j})^2 + (\hat{y}_r(k+1|k) - y_{\ell j})^2}} & \frac{(\hat{y}_r(k+1|k) - y_{\ell j})}{\sqrt{(\hat{x}_r(k+1|k) - x_{\ell j})^2 + (\hat{y}_r(k+1|k) - y_{\ell j})^2}} & 0 \\ \frac{-(\hat{y}_r(k+1|k) - y_{\ell j})}{1 + \left(\frac{\hat{y}_r(k+1|k) - y_{\ell j}}{\hat{x}_r(k+1|k) - x_{\ell j}} \right)^2 (\hat{x}_r(k+1|k) - x_{\ell j})^2} & \frac{1}{1 + \left(\frac{\hat{y}_r(k+1|k) - y_{\ell j}}{\hat{x}_r(k+1|k) - x_{\ell j}} \right)^2 (\hat{x}_r(k+1|k) - x_{\ell j})^2} & -1 \end{bmatrix}$$

Lembrando que

$$h_j(x(k), j) = \begin{bmatrix} \sqrt{(x_r(k) - x_{\ell j})^2 + (y_r(k) - y_{\ell j})^2} \\ \text{atan2}(y_r(k) - y_{\ell j}, x_r(k) - x_{\ell j}) - \theta_r(k) \end{bmatrix}$$

Localização – Filtragem de Kalman – Exemplo – Filtro de Kalman Estendido

A abordagem apresentada assume que a associação entre cada medida com o landmark já conhecido é feita corretamente, sem erros.

Na prática, esta associação pode não ser tão fácil!! já que os landmarks podem ser muito parecidos. Este problema é chamado **Associação de Dados, ou Data Association**.

A idéia básica para a associação de dados é considerar para cada medida i ($y_i(k+1)$) e landmark j um valor de inovação ν_{ij}

$$\nu_{ij} \triangleq y_i(k+1) - h_i(\hat{x}(k+1|k), j)$$

A medida $y_i(k+1)$ é associada ao landmark j que produza a menor inovação de acordo com a norma de Mahalanobis. Esta norma incorpora as incertezas associadas à predição e às medidas.

$$\chi_{ij}^2 = \nu_{ij} S_{ij}^{-1} \nu_{ij}^T,$$

$$S_{ij} = H_i(k+1, j)P(k+1 | k)H_i(k+1, j)^T + W_i(k+1).$$

Localização – Filtragem de Kalman – Exemplo – Filtro de Kalman Estendido




Figura extraída de [1]

Simple SLAM – Filtragem de Kalman

Estado do sistema

$$x = \begin{bmatrix} x_r & y_r & x_{\ell 1} & y_{\ell 1} & x_{\ell 2} & y_{\ell 2} & \dots & x_{\ell n_\ell} & y_{\ell n_\ell} \end{bmatrix}^T$$

Posição do robô

Velocidade no eixo x e no eixo y

Posições dos landmarks

$$x(k+1) = x(k) + \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \\ 0 & 0 \\ \vdots & \vdots \\ 0 & 0 \end{bmatrix} \begin{bmatrix} u_x(k) \\ u_y(k) \end{bmatrix} + \begin{bmatrix} v_{rx}(k) \\ v_{ry}(k) \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Erros associados ao deslocamento

$$x(k+1) = Fx(k) + Gu(k) + v(k)$$

$$V(k) = \begin{bmatrix} V_r(k) & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix}$$

A cada instante de tempo o robô consegue ver todos os landmarks, e pode distingui-los. Não temos o problema de associação de dados.

Simple SLAM – Filtragem de Kalman

Estimativa da posição para o landmark i

$$y_i(k) = \begin{bmatrix} x_{\ell i}(k) - x_r(k) \\ y_{\ell i}(k) - y_r(k) \end{bmatrix} + w_i(k)$$



$$y_i(k) = H_i x(k) + w_i(k),$$

$$H_i = \begin{bmatrix} -1 & 0 & 0 & \cdots & 0 & 1 & 0 & 0 & \cdots & 0 \\ 0 & -1 & 0 & \cdots & 0 & 0 & 1 & 0 & \cdots & 0 \end{bmatrix}$$

Saída produzida pelo Filtro

$$y(k) = H x(k) + w(k),$$

$$H = \begin{bmatrix} H_1 \\ H_2 \\ \vdots \\ H_{n_\ell} \end{bmatrix}, \quad \text{and} \quad w(k) = \begin{bmatrix} w_1(k) \\ w_2(k) \\ \vdots \\ w_{n_\ell}(k) \end{bmatrix},$$

Matriz de covariância associada ao ruído $w(k)$

$$W(k) = \begin{bmatrix} W_1(k) & 0 & \cdots & 0 \\ 0 & W_2(k) & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & W_{n_\ell}(k) \end{bmatrix},$$

Através deste conjunto de equações para o Filtro de Kalman

Estendido, estamos estimando tanto a posição do robô quando dos landmarks

Simple SLAM – Filtragem de Kalman

Como transformar este exemplo em um SLAM efetivo,
capaz de fornecer uma estimativa sobre a posição do robô e dos landmarks desconhecidos presentes no ambiente ?

A chave é verificar se um landmark é novo ou é algum já armazenado no mapa. Isto é feito através norma de Mahalanobis aplicada ao termo de inovação

$$\chi_{ij}^2 = (y(k)_i - h(k)_j)^T S_{ij} (y(k)_i - h(k)_j).$$

Se o valor mínimo encontrado é maior que um dado limiar, então o landmark é novo devendo ser inicializado e adicionado ao mapa.

BIBLIOGRAFIA

- [1] H. Choset, K. Lynch, S. Hutchinson, G. Kantor, W. Burgard, L.Kavraki, S. Thrun. Principles of Robot Motion : Theory, Algorithms, and Implementations. MIT Press. 2005.

- [2] D. Fox, W. Burgard and S. Thrun. Markov Localization for mobile robots in dynamic environments. Journal of Artificial Intelligence Research (JAIR), 11: 391–427, 1999.

- [3] S.Thrun. Learning Metric–Topological Maps for Indoor Mobile Robot Navigation. Artificial Intelligence, v.99, n. 1, 21–71,1998.

- [4]. S. Thrun, W. Burgard, and D. Fox. [Probabilistic Robotics](#). MIT Press, Cambridge, MA, 2005.